ENTERPRISE ARCHITECTURE V2.0

AI Operations Center

Multi-Agent · MCP · RAG · Memory · LangGraph · LangSmith · Security · Multi-LLM

Presentation | Security | Agent Orchestration | RAG | Memory | MCP Tools | LLM Router | Storage | Observability

01 PRESENTATION LAYER

Frontend UI
:3000

Next.js App Router

Chat arayüzü, dosya upload, konuşma geçmişi, LLM seçici, departman seçici ve agent durumu görüntüleme.

chat | file upload | agent status | dept switcher

API Gateway
:8000

FastAPI · Auth · Rate Limit · SSE

Tüm trafiğin giriş noktası. JWT doğrulama, departman bazlı rate limit ve SSE streaming yönetimi.

POST /chat | POST /ingest | PUT /config/llm | GET /agents/status

WebSocket Hub
:8090

Agent-to-Agent · Live Status

Uzun süren agent görevleri için WebSocket kanalı. Birden fazla agent çalışırken anlık durum akışı sağlar.

streaming | agent events | task_id tracking

↓ HTTP / WebSocket / SSE ↓

02 SECURITY & AUTHORIZATION LAYER

JWT Auth

Identity · Department · Role

Her istek için JWT token doğrulama. Token içinde department_id, user_id ve role claim'leri taşınır.

jwt | claims-based

MCP Permission Matrix

Tool-Level ACL

Her departman sadece yetkili MCP sunucularına erişebilir. Policy engine runtime'da kontrol eder.

RBAC | tool-ACL

RAG Namespace Isolation

Data Segmentation

Audit Log

Compliance · Forensics

Qdrant'ta her departmanın kendi collection namespace'i var. Cross-department veri sızıntısı imkânsız.

namespace | tenant isolation

Her agent eylemi, tool çağrısı ve veri erişimi değiştirilemez audit log'a yazılır. PostgreSQL + append-only.

immutable | ISO 27001

DEPARTMAN × MCP YETKİ MATRİSİ

Departman	GitHub MCP	Jira / Confluence MCP
HR / LDAP MCP	Finance DB MCP	Engineering
✓ RW	RO	X
X	Project Mgmt	RO
✓ RW	RO	X
HR	X	RO
✓ RW	X	Finance
X	X	X
✓ RW		

↓ Validated Request + Department Context ↓

03 MULTI-AGENT ORCHESTRATION LAYER · LANGGRAPH

Supervisor Agent

LangGraph Orchestrator · Task Router · Sub-Agent Manager

Tüm alt agent'ları yöneten merkezi otorite. Intent'i analiz eder, görevi doğru agent'a delege eder. Sonuçları birleştirir ve kullanıcıya stream eder. Max 3 paralel sub-agent destekler.

intent routing | task delegation | result synthesis | parallel execution | max 3 concurrent

SUB-AGENTS · UZMANLAŞMIŞ REAct DÖNGÜLERI

Research Agent

RAG + Web Search Uzmanı

Bilgi edinme görevlerini alır. Qdrant'ta hybrid search yapar, SearXNG ile web'e çıkar, cross-encoder ile rerank eder.

RAG | web_search | rerank

Execution Agent

Tool Calling · Eylem Uzmanı

GitHub, Jira, Slack, DB gibi sistemlere yazma işlemleri. MCP üzerinden tool çağırır, sonucu doğrular ve geri döner.

MCP tools | write ops | ACL check

Analytics Agent

Veri Analizi · SQL · Kod

PostgreSQL üzerinde SQL çalıştırır, Python ile analiz yapar. Trend, anomali ve özet rapor üretir.

SQL | execute_python | report gen

Document Agent

Doküman İşleme · Özetleme

Drive, Confluence ve email içeriklerini okur, özetler, karşılaştırır. Uzun dokümanları chunk'layarak işler.

summarize | compare | google-drive

🔔 Notification Agent

Multi-Channel Bildirim

Slack, email ve iç sistemlere bildirim gönderir. Görev tamamlandığında veya kritik durumlarda tetiklenir.

slack MCP | gmail MCP | webhook

🧩 Orchestrator Agent

Cross-Agent Koordinatör

Birden fazla agent'ın çıktısını birleştirmeyi gerektiren kompleks görevler için. DAG tabanlı task planlama.

DAG planning | fan-out | join

LANGGRAPH STATE MACHINE FLOW

User Input → Memory Node → Supervisor Agent → Sub-Agent(s) ⇄ MCP Tools → RAG Node → Synthesis → SSE Stream

↓ Parallel Tool Calls via MCP ↓

04 MCP SERVER LAYER · ENTERPRISE TOOL EXECUTION

GitHub MCP

Engineering · :9001

- get_diff(repo, version)
- list_commits(branch)
- create_issue(title, body)
- review_pr(pr_id)

Jira / Confluence MCP

Project Management · :9002

- get_sprint_status(board_id)
- create_task(project, summary)
- search_confluence(query)
- update_ticket(id, fields)

Google Workspace MCP

Drive · Gmail · Calendar · :9003

- read_doc(file_id)
- search_drive(query)
- send_email(to, subject, body)
- create_event(calendar_id, data)

Slack MCP

Messaging · Notifications · :9004

- post_message(channel, text)
- search_messages(query)
- get_channel_history(channel)
- create_thread(ts, reply)

LDAP / Active Directory MCP

HR · Identity · Access · :9005

- get_employee(uid)
- list_department(dept_id)
- get_groups(user_id)
- search_org_chart(query)

Internal API MCP

Custom Microservices · :9006

- call_service(endpoint, payload)
- query_erp(module, params)
- get_metrics(service, range)
- trigger_workflow(id, context)

Filesystem MCP

Local / NFS Volumes · :9007

- read_file(path)
- write_file(path, content)
- list_directory(path)
- search_files(pattern)

Code Execution MCP

Sandboxed Runtime · :9008

- execute_python(code, timeout)
- run_bash(cmd, sandbox)
- install_package(name)
- get_output(job_id)

Finance DB MCP

Read-Only SQL · Compliance · :9009

- query_transactions(filter)
- get_budget(dept, period)
- revenue_summary(quarter)
- expense_report(uid, range)

↓ Parallel: RAG + Memory + LLM Calls ↓

05 RAG LAYER · RETRIEVAL AUGMENTED GENERATION

Embedding Service

Port :8002 · multilingual-e5-large

50+ dil, 1024 dim vektör. Hem ingest hem query zamanında kullanılır. CPU/GPU otomatik.

1024 dim | 50+ lang

Hybrid Search

α·vector + (1-α)·BM25

Qdrant üzerinde hem semantic hem keyword search. α parametresi runtime'da ayarlanabilir. Top-20 döner.

vector | BM25 | alpha-tune

Cross-Encoder Rerank

ms-marco-MiniLM-L-6-v2

Top-20 sonucu cross-encoder ile yeniden sıralar. Top-5 context'e eklenir. Precision ciddi oranda artar.

top-20 → top-5 | ms-marco

Parent-Child Chunking

Granüler Retrieval

Child chunk ile aranır, parent chunk ile context verilir. Precision + context bütünlüğü aynı anda sağlanır.

parent chunk | child chunk

INGEST AKIŞI

Doküman → Parse + Clean → Parent-Child Chunk → Embed (e5) → Qdrant [dept namespace]

↓ Context Enrichment ↓

06 MEMORY LAYER · MULTI-TIER CONTEXT

Short-Term Buffer

Redis · Sliding Window

Son 20 turn, session_id bazlı. TTL: 2 saat. Her request'te context'e otomatik inject edilir.

Redis | TTL 2h | 20 turn

Long-Term Episodic

Qdrant · Semantic Search

Konuşma bitince önemli olaylar özetlenerek Qdrant memory collection'a yazılır. Benzer geçmiş otomatik bulunur.

Qdrant | vector search

Entity Memory

Redis Hash · User Profile

Summarization Memory

PostgreSQL · LLM Compress

"Ali backend dev, Python tercih ediyor" gibi kalıcı kullanıcı profili. Her konuşmada güncellenir.

Redis | persistent

Buffer dolunca LLM ile konuşmayı özetler, sıkıştırır. Context window'u korur. PostgreSQL'de kalıcı saklanır.

PostgreSQL | compressed

MEMORY INJECT AKIŞI

Request → Entity (Redis) + Episodic (Qdrant) + Buffer (Redis) → System Prompt → LLM

↓ Enriched Context → LLM ↓

07 LLM PROVIDER LAYER · RUNTIME SWITCHABLE

LiteLLM Proxy

:4000

Universal OpenAI-Compatible Router

Tüm provider'ları tek OpenAI-compat interface'e çevirir. LangGraph tarafı değişmez. Runtime'da config.yaml güncellenir. Fallback zinciri destekler.

fallback chain | cost tracking | config.yaml

PROVIDER POOL

vLLM LOCAL :8080 | OpenAI | Anthropic | Groq | Gemini | Mistral | Azure OpenAI

Yeşil = aktif lokal model. External provider için kullanıcı API key girer. Fallback: external fail → local vLLM.

vLLM

:8080

Qwen2.5-14B-Instruct · PagedAttention

Continuous Batching, max 256 concurrent request. Native tool calling: --tool-call-parser hermes. GPU zorunlu.

tool calling | PagedAttention | GPU

Embedding Service

:8002

multilingual-e5-large-instruct

Hem RAG hem Memory layer tarafından kullanılır. Cross-encoder reranker aynı serviste. CPU/GPU hybrid.

1024 dim | reranker

↓ Persist · Index · Cache ↓

08 STORAGE LAYER

Qdrant

:6333

Vector DB · Multi-Namespace

Her departman için ayrı namespace. documents (RAG) + memory (episodic) collections. Hybrid search native destekli.

namespaced | hybrid

Redis

:6379

In-Memory · Persistent

Short-term buffer (TTL 2h), entity memory (persistent Hash), session cache ve agent task state.

Redis | entity | buffer

PostgreSQL

:5432

Relational · Audit

Konuşma geçmişi, LLM özetleri, audit log (append-only), agent task history ve

Data Volumes

Docker Volumes · NFS

Tüm servisler Docker volume mount ile persist edilir. Restart'ta veri kaybolmaz. NFS ile

LangSmith mirror.

audit log | summaries

cluster genelinde erişilebilir.

persistent | NFS

↓ Trace · Monitor · Evaluate ↓

09 OBSERVABILITY LAYER · LANGSMITH + METRICS

LangSmith Tracing

Full Chain Visibility

Her LangGraph node'u otomatik trace edilir. Agent kararları, tool calls, RAG chunk relevance ve memory ops görünür.

node traces | LLM calls | tool traces

RAG Evaluation

LLM-as-Judge

Retrieve edilen chunk'ların relevance score'ları. Rerank öncesi/sonrası karşılaştırma. Dataset kaydetme ve otomatik kalite değerlendirmesi.

relevance | rerank eval

Cost & Latency Dashboard

Per Agent · Per Department

Her agent çağrısının token kullanımı, maliyet tahmini ve latency. Departman bazlı bütçe takibi yapılabilir.

cost per run | latency P95

10 DEPARTMAN BAZLI KULLANIM SENARYOLARI

⚙ Engineering

> "v2.4 release'inde bellek sızıntısı neden oldu?"

Research Agent → GitHub MCP ile diff çeker → **Analytics Agent** → log dosyalarını analiz eder → Supervisor birleştirir

GitHub MCP Filesystem MCP Code Exec MCP

📋 Project Management

> "Pazarlama kampanyasında kimler görevli, nerede gecikme var?"

Document Agent → Drive'dan strateji okur → **Analytics Agent** → Jira board'u çeker → özet + uyarı

Jira MCP Google Drive MCP Slack MCP

💼 Sales & Support

> "Geçen hafta en çok şikayet gelen ürün ne, müşterilere ne cevap verildi?"

Analytics Agent → DB'den hata kayıtları → **Document Agent** → Gmail tarar, şablon bulur

Internal DB MCP Gmail MCP Confluence MCP

💰 Finance

> "Q3 bütçe sapmaları neler, hangi departmanda fazla harcama var?"

Analytics Agent → Finance DB MCP (read-only SQL) → trend analizi → özet rapor PDF

Finance DB MCP Code Exec MCP

👥 Human Resources

> "Ocak'ta işe başlayan çalışanlar için onboarding görevleri oluştur."

Execution Agent → LDAP'tan isim listesi → Jira'da task oluştur → Slack'te bildirim gönder

LDAP MCP Jira MCP Slack MCP

🚨 Cross-Department

> "Bu haftanın sprint'ini özetle, geride kalınan task'ları Slack'e bildir."

Orchestrator Agent → 3 sub-agent paralel çalışır → sonuçları join eder → Notification Agent devreye girer

Jira MCP GitHub MCP Slack MCP Drive MCP

11 END-TO-END REQUEST AKIŞI

01 İstek Giriş
Kullanıcı mesaj yazar → JWT doğrulama → department_id + session_id + message ile POST /chat

02 Yetki Kontrolü
Role + department → MCP ACL matrix kontrol → namespace isolation doğrulama → audit log yazımı başlar

03 Memory Inject
Redis'ten short-term buffer + entity facts çek → Qdrant'tan episodic memory semantic search → sistem promptuna ekle

04 Supervisor Routing
Supervisor Agent intent'i analiz eder → hangi sub-agent(ler) çalışacak karar verir → paralel task dispatch

05 RAG Retrieval
Research Agent:

06 MCP Tool Loop
Execution Agent: LiteLLM → tool_call → MCP Server → tool execute (ACL check) → ToolMessage → ReAct loop (max 10)

07 LLM Inference
LiteLLM proxy → aktif provider (vLLM veya external) → streaming completion → SSE ile frontend'e akar

08 Result Synthesis
Supervisor tüm sub-agent çıktılarını birleştirir → Orchestrator Agent gerekirse yeniden sıralar → final response hazır

09 Memory Write
Response Node: Redis buffer güncelle + Qdrant episodic write + entity update → PostgreSQL'e konuşma kaydet

∞ Observability
Tüm adımlar LangSmith'e trace

query
embed
→
Qdrant
hybrid
search
[dept
namespace]
→
cross-
encoder
rerank
→
top-
5
chunk
context'e
→
audit
log'a
yazıldı
→
cost
+
latency
dashboard
güncellendi

12 DOCKER COMPOSE · FULL SERVICE MAP

:3000
frontend
Next.js UI

:8000
orchestrator
FastAPI + LangGraph

:4000
litellm-proxy
LLM Router

:8080
vllm
Local LLM · GPU

:8002
embedding
e5 + reranker

:8001
mcp-server
FastMCP hub

:9001-9
mcp-[tools]
GitHub·Jira·Drive···

:6333
qdrant
Vector DB

:6379
redis
Short-term · Entity

:5432
postgres
History · Audit

:8888
searxng
Local web search

ext
LangSmith
Trace only · SaaS

`docker compose up -d` → **~20 container** · 1 overlay network · GPU passthrough (nvidia runtime) · tüm data volume'larda persist · **sıfır dış bağımlılık** (LangSmith + opsiyonel external LLM hariç)

ENTERPRISE AI OPERATIONS CENTER · V2.0

Multi-Agent · MCP · RAG · Memory · Security · LangGraph · LangSmith